

多模态情感特征提取与时序对齐

问题一的分析与数学建模

针对附件 1 中 100 条英文视频，建立以词级时间区间为统一索引的三模态特征提取模型。模型将文本上下文表示、声学描述符、面部表情与头部姿态映射到同一词序列，同时保留原始帧级特征、时间映射和质量掩码。现有运行结果覆盖全部样本，共生成 1931 个词级位置，语音有效覆盖率为 100%，视觉有效覆盖率为 82.91%；结构与聚合复算检查未发现错误。上述指标反映数据生成与可用性，不代表人工验证的对齐准确率。

关键词 多模态特征提取；CTC 强制对齐；Viterbi 算法；时间重叠加权；可追溯时序表示

1 问题分析

1.1 任务目标与研究边界

问题一要求从原始素材出发，给出特征定义、提取方法以及跨模态时序组织规则。与直接使用预计算特征不同，本问需要说明每个数值向量来自哪段文本、哪段语音及哪些视频帧。因此，模型的主要输出是可核验的时序特征文件，而不是情感极性 or 情感强度的预测结果。本文仅使用赛题提供的样本，预训练工具用于冻结参数的基础处理，不使用情感标签训练或微调特征提取器。

1.2 异构模态带来的建模困难

文本以离散词语承载语义，音频是连续采样信号，视频则以帧记录面部状态。三者既有采样频率差异，也有表示维度和有效观测范围差异。若仅将序列裁剪到相同长度，则相同下标未必对应同一段内容；若对整句直接求平均，则会丢失局部情感变化和证据位置。另一方面，画外音、遮挡及转写不匹配可能使某些模态的局部信息不可用，需将“没有观测”与“观测值恰为零”明确区分。

1.3 以词为时序锚点的解决思路

本文先独立提取各模态特征，再利用已知转写与音频进行强制对齐，为每个词确定时间区间，最后按区间重叠长度聚合语音和视觉特征。词级索引兼顾语言可读性与时间可定位性，便于将数值输出回查至原始素材。对齐低分、无人脸及多人脸情况通过独立标记保留，不通过删除样本提高表面覆盖率。

表 1 问题一的要求与对应实现

题目要求	实现方式	核验材料
样本覆盖完整	100 条样本逐一匹配并保留	清单、特征文件、源视频哈希
时序组织可核验	词区间、源帧索引、有效长度与掩码	逐词明细与典型样本图
方法可复现	固定配置、模型修订号与处理日志	环境快照、代码与运行说明

2 模型假设与符号说明

2.1 建模假设及适用条件

第一，容器中的音频、视频时间戳可作为建立公共时间轴的依据。程序使用实际解码时间戳而非单纯按帧号除以帧率换算；存在音频缺口时保留观测掩码。该假设不排除源视频本身已有音画偏移，因此所得对应关系仍受素材质量限制。

第二，给定转写可作为强制对齐的目标序列，但不假定其与音频始终一致。数字读法采用显式映射，不修改原始文本；无法建立合法路径时标记失败，低分路径保留复核信息。该处理把文本一致性作为需要检查的条件，避免把强制匹配误写为已证实的正确匹配。

第三，源帧特征在其短时间支持区间内可由当前帧代表，因而能用时间重叠长度进行加权。该近似适合构造词级统计量，但会平滑词内变化；原始帧级数据同时保存，允许后续使用更细粒度方法重新分析。

第四，视觉端每帧选择最大人脸作为候选表达主体。这是确定性选择规则，而不是已验证的说话人识别假设。多人脸与低检出率场景需回看，不能仅凭人脸面积确定该人正在发声。

2.2 主要符号

表 2 数学符号及其含义

符号	定义或含义
n, N	样本索引与样本总数，本问 $N = 100$
D_n, L_n	第 n 条样本的解码时长与词数
w_i, S_i	第 i 个词及其对应的文本子词下标集合
$I_i = [s_i, e_i)$	第 i 个词在公共时间轴上的区间
$J_j = [g_j, f_j)$	第 j 个声学帧或视觉帧的时间支持区间
x_j, m_j	源帧特征向量与有效观测指示量
$p_t(c), \ell$	第 t 个声学时间步的字符概率与目标字符序列
$z_s, \delta_t(s)$	CTC 增广状态的符号及到达状态的最优对数分数
q_i, r_i	词级对齐分数及低分复核标记
w_{ij}, W_i	词与源帧的重叠权重及该词的总权重
μ_i, σ_i	重叠加权均值向量与逐维标准差向量
X^t, X^a, X^v	词级文本、语音、视觉特征矩阵

为简化表达，后文在单条样本内省略样本下标 n 。时间单位统一为秒，区间采用左闭右开约定。模态掩码为 **True** 表示存在有效观测贡献；补齐掩码为 **True** 表示批量输入中人为增加的位置，二者含义相反。

3 总体框架与原始数据处理




图 1 从原始素材到词级三模态特征的处理流程

3.1 样本编号与输入完整性

程序读取附件 1 的 label-100.xlsx，以 video_id 与 clip_id 共同定位视频，并构造唯一标识 video_id\$_clip_id。读取时核验样本总数为 100、编号无重复、表格视频集合与磁盘视频集合一致，并检查标签取值与正负中性含义。原转写和标签原样写入元数据；标签只用于一致性核验及结果登记，不进入特征提取或对齐的目标函数。

3.2 公共时间轴与观测掩码

使用 PyAV 解码，取容器起始时刻为时间原点。若某帧具有呈现时间戳 PTS 及对应时间基，则其相对时刻按式（1）计算。音频通过重采样器转换为 16 kHz 单声道，并根据重采样帧的时间戳放入公共采样数组，而不是忽略偏移后直接拼接。

$$t = \text{PTS} \times \text{time_base} - t_0 \quad (1)$$

音频数组初始化为零，同时建立同长度的观测布尔数组。写入真实解码数据的位置记为已观测，其余位置仍为未观测。零值在此只承担存储占位作用，后续声学有效性判断还需检查观测比例。因此，容器缺口与实际静音被保留为不同状态。缺失声学上下文仍可能影响强制对齐，这属于后续复核范围。

3.3 文本清理与时间口径

分词规则保留英文缩写中的撇号、带千分位的数字及序数词，并登记原文字符偏移。标点保留在原始文本中，但不作为独立词级特征位置；连字符连接的词按规则拆分。音频对齐使用单独的字符规范化副本，避免对赛题原文作不可追溯修改。

现有处理结果的解码总时长为 787.5022 秒，单条范围为 2.2570 至 29.2881 秒。该范围与题面所述范围不同，本文不据此替换或裁剪视频，而在全量表中统一报告程序记录的解码时间轴长度。时长定义和源文件哈希共同保留，便于对差异进一步复核。

4 三模态情感相关特征的构建

4.1 文本上下文表示

文本采用冻结的 DistilBERT 英文编码器[1]。将分词结果作为预分词输入，模型进一步产生子词序列和 768 维最后隐层输出。一个原词可能对应多个子词，若直接使用子词位置将与音频词区间不一致，因此依据分词器返回的 word_ids 建立映射，对属于同一词的隐层向量取均值：

$$x_i^t = \frac{1}{|S_i|} \sum_{j \in S_i} h_j, \quad X^t \in \mathbb{R}^{L \times 768} \quad (2)$$

程序按最多 100 个原词分块编码，不静默截断；若子词数量超过模型允许长度，则报错要求减小块大小。当前样本最长 65 词，均在单个词块内处理。该表示保留块内上下文，但预处理时去掉了作为独立标点的输入，不能声称完全保留原句全部语言线索。语义向量也不直接对应正负情绪概率，其情感判别价值需在下游任务中检验。

4.2 语音低层声学描述符

语音使用 openSMILE 2.6.0 的 eGeMAPSv02 低层描述符配置[3]，每个声学帧输出 25 维向量。选用帧级描述符是为了保留后续按词聚合的时间自由度；该输出并非整句 88 维统计特征。特征起止时刻直接采用工具返回的帧区间，避免另行假定固定窗口后造成错位。

表 3 25 维声学描述符的组成

特征组	主要内容	维数
能量与频谱	响度、alphaRatio、Hammarberg 指数、两段谱斜率、谱通量	6
倒谱	第 1 至第 4 阶 MFCC	4
基频与音质	半音基频、局部抖动、微颤、谐波比 HNR	4
谐波差异	H1-H2、H1-A3 相关对数相对量	2
共振峰	前三个共振峰的频率、带宽及相对幅度	9
合计	按 feature_names.json 固定列顺序保存	25

为避免未观测音频对统计量造成污染，代码计算每帧区间内真实音频采样点的占比 ρ_j ，同时检查各维数值是否有限。仅当观测比例不低于 95%且数值全部有限时，该声学帧参与词级聚合：

$$m_j^a = 1\{\rho_j \geq 0.95\} \cdot 1\{x_j^a \text{各维均为有限值}\} \quad (3)$$

这项规则只排除缺失或数值异常帧，并不将所有背景噪声或非语音片段识别为无效。基频为零也不能在此处简单等同于缺失。声学特征的物理含义与质量掩码应结合解释，最终通过词区间内均值和标准差得到 50 维词级表示。

4 三模态情感相关特征的构建

4.3 面部表情与头部姿态

视觉端按 10 Hz 目标频率选取具有真实 PTS 的视频帧。程序依次解码，当帧时刻到达下一个目标采样位置时保留该帧，并据实际时刻更新下一采样门限；因此采样间隔可随原视频时间戳变化。图像宽度超过 640 像素时等比例缩小，限制的是宽度而非最长边。

采用 MediaPipe Face Landmarker[4]检测至多 3 张人脸，检测与存在置信度阈值均为 0.5。多张人脸时依据关键点包围框面积选择最大者。对被选人脸读取 52 维 blendshape 系数与面部变换矩阵；前者表示表情混合形状系数，不等同于 FACS 动作单元，也不能直接视为情感类别。



图 2 典型样本的原始视频采样帧及可回查位置

设变换矩阵左上角 3×3 部分为 A 。为从可能含尺度因素的矩阵中得到合法旋转，先作奇异值分解 $A = U\Sigma V^T$ ，再校正行列式符号，得到旋转矩阵 R ，并转为 xyz 顺序的欧拉角。角度使用弧度制：

$$R = U \text{diag}(1, 1, \det(UV^T)) V^T \quad (4)$$

$$x_j^v = [b_{j,1}, \dots, b_{j,52}, \theta_{j,x}, \theta_{j,y}, \theta_{j,z}] \in \mathbb{R}^{55} \quad (5)$$

相邻采样时刻的中点构成帧支持区间边界，且每帧向左右的支持范围均限制在 0.075 秒以内，首末区间再限制于视频时长内。该规则防止跨越较大解码缺口。检测失败或数值无效时置零并记 $m_j^v = 0$ ；同时保留人脸数、选中框和原始帧号，使视觉选择及缺失可回查。图 2 中的采样时刻是帧 PTS，是否参与某词聚合由支持区间重叠决定，不能只比较中心点是否落在词区间内。

5 基于 CTC 的词级强制对齐模型

5.1 目标序列与最大概率路径

使用 Wav2Vec2 英文 CTC 声学模型[2]获得音频各时间步的字符对数概率。转写先大写化，对登记过的数字与序数词进行读法展开，例如 10th 展开为 TENTH；词间插入词分隔符“|”。需要区分词分隔符与 CTC blank：前者是目标字符，后者用于状态停留和重复字符分离。原文与字符所属原词的映射同时保留。

$$\pi^* = \arg \max_{\pi \in \mathcal{A}(\ell)} \sum_t \log p_t(\pi_t) \quad (6)$$

式（6）中 $\mathcal{A}(\ell)$ 表示能够折叠为目标序列 ℓ 的合法 CTC 路径集合。此处求解的是固定声学后验下的最优受约束路径，不涉及重新训练声学模型。将目标扩展为 $z = (\text{blank}, \ell_1, \text{blank}, \dots, \ell_k, \text{blank})$ ，用 $\delta_t(s)$ 记录到达第 s 个状态的最大对数分数。

5.2 Viterbi 动态规划与回溯

$$\delta_t(s) = \log p_t(z_s) + \max_{u \in P(s)} \delta_{t-1}(u) \quad (7)$$

前驱集合 $P(s)$ 始终包含合法范围内的 s 与 $s-1$ ；只有 z_s 不是 blank 且 z_s 与 z_{s-2} 不同，才允许加入 $s-2$ 。初始化时仅首个 blank 与首个目标字符可达，其余状态设为负无穷。终止时从最后一个字符或末尾 blank 中选择较大分数，依据记录的转移回溯完整路径。若终止状态不可达，则报告对齐失败。




图3 重复字符必须经过 blank 的完整 CTC 转移约束

5.3 声学帧到秒的换算

Wav2Vec2 卷积前端的总步幅为 320 个采样点、感受野为 400 个采样点。对 16 kHz 输入，时间步长 $\Delta t = 0.020$ 秒，首个感受野中心 $c_0 = 399/(2 \times 16000)$ 。以中心之间的中点构造帧单元边界并裁剪至 $[0, D]$ ：

$$b_k = \text{clip}(c_0 + (k - 1/2)\Delta t, 0, D) \quad (8)$$

若某词首字符起于帧 u ，末字符止于帧 v （含 v ），则词区间为 $[b_u, b_{v+1})$ 。这样得到的 20 毫秒步长是离散时间分辨率，不能据此声称词边界误差小于 20 毫秒。重复字符拓扑保证路径合法性，但无法消除转写错误或声学识别偏差。

6 词级聚合与质量标记模型

6.1 对齐置信度的定义

对目标字符 k ，设 F_k 为回溯路径中发射该字符的声学帧集合，先对字符发射概率取几何平均得到 c_k ；再对属于词 i 的字符集合 C_i 取几何平均得到 q_i 。该两级平均与代码一致，使每个目标字符在词分数中具有相同权重，而非让发射帧较多的字符获得更高权重。

$$c_k = \exp\left[\frac{1}{|F_k|} \sum_{t \in F_k} \log p_t(\ell_k)\right] \quad (9)$$

$$q_i = \exp\left[\frac{1}{|C_i|} \sum_{k \in C_i} \log(\max(c_k, 10^{-30}))\right] \quad (10)$$

定义复核标记 $r_i = 1 \{q_i < 0.1 \text{ 或对齐失败}\}$ 。阈值 0.1 是当前配置中的检查门限，未经人工边界真值校准，不是错误概率阈值。低分词仍保留时间区间与特征；没有合法路径时保留文本位置，词区间与对齐掩码置为无效，并保存原始声学、视觉数据。

6.2 按时间重叠进行加权统计

$$w_{ij} = \max(0, \min(e_i, f_j) - \max(s_i, g_j)) \cdot m_j \quad (11)$$

$$W_i = \sum_j w_{ij}, \quad \mu_i = \frac{1}{W_i} \sum_j w_{ij} x_j \quad (12)$$

$$\sigma_i = \sqrt{\frac{1}{W_i} \sum_j w_{ij} (x_j - \mu_i)^2} \quad (13)$$

式 (12) 与式 (13) 仅在 $W_i > 0$ 时计算，平方和开方按特征维逐项进行。均值描述词内平均状态，标准差补充词内变化幅度。将二者拼接后，语音由 25 维变为 50 维，视觉由 55 维变为 110 维；文本仍保持 768 维。累加过程使用 float64，保存时转为 float32，以减少大数值常量描述符的舍入误差。




图 4 时间重叠加权与无效帧排除的数值示例

6.3 缺失与未分配区间

当 $W_i = 0$ 时，输出零向量并将该词的模态掩码置 False； $W_i > 0$ 只说明存在有效贡献，不保证覆盖整个词区间。词间未分配区间取所有有效词区间在 $[0, D]$ 内的补集，单独保存而不会自动称为静音。帧级聚合会压缩词内先后顺序，因此原始帧特征及其时间戳一并保留，以支持复算与更细的时序分析。

7 算法实现与特征文件规范

7.1 单条样本的执行逻辑

主程序由 `process_one` 串联处理。首先按真实时间戳解码音频并分词；随后获得词级文本向量与强制对齐区间；再提取帧级声学 and 视觉特征，调用统一的区间聚合函数；最后计算质量提示，检查输出数值有限性，并保存压缩数组和元数据。异常采用逐样本日志记录，全局失败计数使运行结束状态可检查。

表 4 核心函数与数学模型的对应关系

代码位置	功能	对应对象
<code>read_manifest</code>	读取并核验输入清单	样本与视频的一一对应
<code>media_audio</code>	解码、重采样及观测登记	式（1）与公共时间轴
<code>text_features</code>	子词隐层向量平均	式（2）
<code>audio_features / visual_features</code>	帧级提取与有效性检查	式（3）至式（5）
<code>align / ctc_viterbi</code>	声学后验、动态规划与回溯	式（6）至式（10）
<code>pool_intervals</code>	时间重叠加权均值与标准差	式（11）至式（13）
<code>collate</code>	按批内最长序列补齐	补齐掩码与有效长度

7.2 文件字段与追溯关系

每条样本输出一个 NPZ 数值文件和一个 JSON 元数据文件。NPZ 保留三模态词级矩阵、原始帧特征及掩码；JSON 保存原始文本、标签、字符与子词映射、每词参与聚合的源帧索引、源文件和输出文件哈希、处理指纹与告警。由“词索引—时间区间—源帧索引—视频路径”可定位原始证据。

表 5 主要输出字段与形状

字段	形状或类型	含义
<code>text / audio / vision</code>	$L \times 768 / L \times 50 / L \times 110$	三模态词级特征
<code>word_intervals</code>	$L \times 2$	每词起止时间
<code>word_char_offsets</code>	$L \times 2$	原文字符起止偏移
<code>alignment_confidence</code>	L	对齐分数，未校准
各模态 <code>mask</code> 与 <code>alignment_mask</code>	L 个布尔值	观测有效性及路径有效性
<code>alignment_review_mask</code>	L 个布尔值	低分或失败复核标记
<code>audio_raw / vision_raw</code>	$F_a \times 25 / F_v \times 55$	帧级特征与配套时间字段
<code>valid_length / padding_mask</code>	整数 / L 个布尔值	实际词数与补齐标记

7.3 变长存储和计算复杂度

磁盘保存完整变长序列，不强制截断为 50 词。批量读取时按该批最长词数补零，补齐掩码设为 `True`，模态有效掩码设为 `False`。若 CTC 时间步数为 T 、目标字符数为 K ，动态规划的时间复杂度为 $O(TK)$ ，回溯表空间为 $O(TK)$ ；当前区间聚合逐词检查源帧，复杂度为 $O(L(F_a + F_v))$ ，适用于本问短视频规模。

8 全量结果与质量分布

对附件 1 的 100 条样本完成提取，共保留 1931 个词。每条样本均有词级时间区间和有效语音贡献，视觉有效词为 1601 个，另有 330 个词未获得有效人脸特征。图 5 展示解码时长、词数和质量指标的实测分布。




图 5 全量 100 条样本的规模与特征可用性分布

表 6 全量结果的主要统计量

指标	结果	统计口径
样本完成数	100 / 100	成功生成特征与元数据
总时长与总词数	787.5022 秒；1931 词	解码时间轴；完整分词序列
词级时间区间与语音覆盖	100%；100%	均为 1931 / 1931
视觉有效词比例	82.91%	1601 / 1931
采样帧有效人脸比例	81.91%	6462 / 7889
低分词与低均分样本	342 词；18 条样本	词分数或样本均分低于 0.1
含复核提示样本	69 / 100	各类告警的样本并集
压缩特征体积	14.28 MiB	仅 100 个 NPZ 文件

样本词数从 5 至 65 不等，其中 1 条超过 50 词，说明完整变长存储能够避免固定长度截断。低分词占 17.71%，需要结合回听判断原因；另外 20 个采样帧存在多人脸。不同告警可以同时出现在同一条样本中，不能直接相加解释为告警样本数。

视觉未覆盖可能与无人脸、遮挡或检测失败等因素有关，但现有数据仅支持“缺少有效视觉贡献”的结论，尚未逐条人工归因。图 5 (d) 展示两种质量信号的联合分布，不构成因果关系或性能提升证明。完整逐样本数值见表 9。

9 典型样本的时序对应验证

按原表顺序，选择首条全部词可对齐、无低分词、人脸有效率大于 80%且无多人脸采样帧的样本-THoVjtIkeUS_\$2。其解码时长约 4.29 秒，转写为“I think social justice is extremely important for young people.”。选择规则只用于展示，不能代替全量质量评价。




图 6 典型样本的词区间 音频波形 基频描述符与面部系数

图 6 横轴为视频起点后的秒数。第一行是强制对齐生成的词区间，后续行分别展示音频波形、半音基频描述符及部分面部系数。词区间之间的空白仅表示未分配给目标词的时段。图 2 进一步提供可回看的采样帧，与表 7 共同构成从文本到源素材的对应证据。

表 7 典型样本的逐词对齐结果

词	起点/s	终点/s	分数	语音帧数	视觉帧数
I	0.042	0.062	0.802	4	2
think	0.162	0.382	1.000	24	3
social	1.202	1.442	0.985	26	3
justice	1.502	1.782	0.984	30	4
is	1.862	1.902	0.999	6	1
extremely	1.982	2.362	0.987	40	5
important	2.422	2.782	1.000	38	5
for	2.862	2.982	0.999	14	2
young	3.082	3.242	1.000	18	2
people	3.322	3.702	0.342	40	5

例如 important 对应 2.422 至 2.782 秒，由 38 个有效声学帧和 5 个有效视觉支持区间贡献，最终生成 768/50/110 维三模态向量。people 分数约 0.342，虽然低于多数其他词，但高于 0.1 门限，不属于当前规则下的低分词；仅凭该分数不能推断发音截断。上述对应关系属于可视核验展示，尚无人工逐词边界真值用于计算时间误差。

10 结果核验与可复现性

10.1 结构核验和独立数值复算

汇总程序对全部特征检查样本身份、原文与标签一致性、输出文件哈希、有效长度、特征形状、有限数值、字符偏移回读、词区间正长度与单调性、视频 PTS 顺序。随后从保存的帧级特征重新计算词级聚合，核对结果、掩码和源帧索引。数值比较采用相对容差与绝对容差均为 2×10^{-5} 的 allclose 规则，并非声称所有绝对误差都小于 2×10^{-5} 。

现有 validation.json 记录结构与数值检查错误列表为空。另有 6 项算法检查覆盖重复字符 blank 约束、不可行路径、无效帧排除与加权聚合、字符偏移与区间补集、数字分词以及超过 50 词的批量补齐。结构正确和复算一致只验证实现与保存规则，不验证词语的真实发音边界或说话人身份。

10.2 固定配置与环境记录

表 8 运行环境与主要参数

组件或配置	当前记录	用途
Python / NumPy / SciPy	3.12.14 / 1.26.4 / 1.13.1	数值计算与旋转处理
PyTorch / Transformers	2.8.0 / 4.57.6	冻结模型推理
PyAV / openSMILE	14.2.0 / 2.6.0	音视频解码与声学提取
MediaPipe	0.10.21	人脸与表情系数提取
DistilBERT 修订号	12040accade4...	完整修订号见环境快照
Wav2Vec2 修订号	22aad52d435e...	完整修订号见环境快照
音频采样率 / 视频采样率	16000 Hz / 10 Hz	公共时间轴与采样配置
人脸阈值 / 对齐复核阈值	0.5 / 0.1	观测筛选与复核提示
文本词块 / CPU 线程 / 随机种子	100 / 4 / 20260923	可复现参数

预训练模型在准备阶段下载并登记修订号和逐文件哈希，正式提取阶段强制离线。源视频、标注表、代码、模型清单和配置均留有版本证据。断点续跑只有在处理指纹、源视频哈希和输出哈希均一致时跳过样本，避免直接沿用来源不明或已损坏的缓存。

10.3 复现流程与交付组织

依照 requirements-lock.txt 建立环境后，执行 prepare_models.py 准备模型，再运行 run.ps1。入口依次调用算法检查、pipeline.py 全量提取、summarize.py 核验与汇总以及 package_results.py 打包。独立读取通过 read_features.py 完成，无需加载 pickle 对象。

若仅调整聚合规则，可利用 reaggregate.py 从保存的原始帧特征重算，避免重新提取深度表示。本次结果记录了以 float64 累加器重算词级聚合的处理历史。压缩特征 14.28 MiB 不等于全部提交附件体积，最终提交还需统计代码、说明等文件，并按赛题统一限制检查总大小。

11 模型评价与结论

11.1 方法的合理性与适用范围

本文把跨模态组织转化为“已知文本的时间定位”和“异步帧特征的区间统计”两个可计算子问题。前者由完整 CTC 拓扑约束的动态规划求解，后者由统一的时间重叠权重定义。两部分均具有明确输入、输出与失败规则，使特征生成不仅得到矩阵，还能提供矩阵位置与原始素材之间的对应记录。

词级序列保留局部语言单位，均值与标准差同时描述区间内平均状态与波动。独立模态掩码能区分可用贡献和缺失位置，原始帧数据允许重新聚合。由于没有利用情感标签调整提取器，本问结果可作为基础表示与审计材料；但是否改善情感分类或回归，仍需后续模型与验证集实验支持。

11.2 局限性与可实施的改进

一是强制对齐对转写一致性敏感。18 条样本平均分数低于 0.1，应优先回听源音频，并对照保存的转写与模型直接识别文本区分原因；不能自行替换题目转写。二是 10 Hz 视觉采样和词级统计会压缩短暂动作及词内先后顺序，最大人脸规则也可能选错主体。可在后续人工复核后评估更密采样或说话人确认，但这些改进尚未在当前结果中完成。

三是目前没有人工逐词边界真值，无法报告平均边界误差、对齐准确率或校准后的置信度。可预先制定抽样规则，标注起止时间，再计算误差及分数分层表现。四是当前 768/50/110 维特征与附件 2 的 768/74/35 维接口不同；问题二、三如采用附件 2 训练，应保持附件 2 规定的输入版本，不能将本问特征直接替换为同义输入。

11.3 本问结论

模型已为 100 条样本生成完整的词级三模态表示与追溯信息。1931 个词均获得时间区间和有效语音贡献，1601 个词具有有效视觉贡献；342 个低分词及其他异常均保留复核标记。实现层面满足全量覆盖、可核验时序组织和复现记录要求，质量层面仍需人工边界标注与异常回看，不能将可用性统计外推为情感预测性能。

参考资料

- [1] DistilBERT community. distilbert-base-uncased 模型卡[EB/OL]. <https://huggingface.co/distilbert/distilbert-base-uncased>, 访问日期 2026-09-24.
- [2] Meta. wav2vec2-base-960h 模型卡[EB/OL]. <https://huggingface.co/facebook/wav2vec2-base-960h>, 访问日期 2026-09-24.
- [3] audEERING. openSMILE Python Documentation[EB/OL]. <https://audeering.github.io/opensmile-python/>, 访问日期 2026-09-24.
- [4] Google. Face landmark detection guide[EB/OL]. https://developers.google.com/edge/mediapipe/solutions/vision/face_landmarker, 访问日期 2026-09-24.
- [5] 赛题材料. 复杂场景下多模态情感预测的数学建模与算法设计及附件 1, 2026.
- [6] 问题一程序与运行记录. pipeline.py, alignment.py, summarize.py 及 results 目录下全量特征、统计表和环境快照, 2026.

12 全量样本特征提取结果

表 9 按源表顺序列出全部 100 条样本。每条均包含文本 T、语音 A 和视觉 V，维度统一为 768/50/110，粒度均为词级；因此将共有字段置于表注，逐行保留时长、词数及有效性。时长采用公共解码时间轴口径；A/V 为语音和视觉有效词数，低分为 $q < 0.1$ 的词数。

表 9 全部样本的逐条结果 第 1 至 34 条

序号	样本编号	时长/s	词数	A	V	低分	状态
1	-3g5yACwYnA\$ _\$13	5.514	15	15	15	1	复核
2	-3g5yACwYnA\$ _\$3	14.389	29	29	29	1	复核
3	-3g5yACwYnA\$ _\$2	9.394	14	14	14	1	复核
4	-3g5yACwYnA\$ _\$9	8.817	23	23	23	2	复核
5	-3nNcZdcdvU\$ _\$5	7.868	18	18	18	1	复核
6	-HwX2H8Z4hY\$ _\$2	3.982	7	7	1	3	复核
7	-HwX2H8Z4hY\$ _\$5	5.653	9	9	2	0	复核
8	-HwX2H8Z4hY\$ _\$6	3.358	7	7	5	0	复核
9	-HwX2H8Z4hY\$ _\$9	7.734	22	22	0	2	复核
10	-NFrJFQijFE\$ _\$1	5.746	16	16	0	16	复核
11	-NFrJFQijFE\$ _\$2	6.856	18	18	0	18	复核
12	-THoVjtIkeU\$ _\$12	14.896	39	39	39	1	复核
13	-THoVjtIkeU\$ _\$2	4.292	10	10	10	0	正常
14	-THoVjtIkeU\$ _\$6	8.097	30	30	30	3	复核
15	-UuX1xuaiiE\$ _\$1	10.350	27	27	1	0	复核
16	-UuX1xuaiiE\$ _\$0	3.633	9	9	6	1	复核
17	-UuX1xuaiiE\$ _\$3	4.130	9	9	9	0	正常
18	-UuX1xuaiiE\$ _\$6	8.114	22	22	22	2	复核
19	-a55Q6RWvTA\$ _\$3	22.154	65	65	61	2	复核
20	-aNfi7CP8vM\$ _\$7	8.695	18	18	18	0	正常
21	-aqamKhZlEc\$ _\$0	10.967	14	14	14	0	复核
22	-dxftGcXJoc\$ _\$1	16.161	36	36	36	0	复核
23	-dxftGcXJoc\$ _\$0	20.500	40	40	32	0	复核
24	-dxftGcXJoc\$ _\$2	16.698	34	34	34	1	复核
25	-dxftGcXJoc\$ _\$6	12.735	28	28	28	1	复核
26	-cgA8-b7-3M\$ _\$26	6.031	15	15	15	0	正常
27	-cgA8-b7-3M\$ _\$17	7.271	16	16	16	0	正常
28	-cgA8-b7-3M\$ _\$18	8.386	22	22	22	0	正常
29	-cgA8-b7-3M\$ _\$16	5.538	11	11	11	0	正常
30	-cgA8-b7-3M\$ _\$13	4.184	11	11	11	0	正常
31	-cgA8-b7-3M\$ _\$1	10.266	20	20	20	0	复核
32	-cgA8-b7-3M\$ _\$6	6.265	12	12	12	0	正常
33	-cgA8-b7-3M\$ _\$9	5.090	10	10	10	0	正常
34	-cgA8-b7-3M\$ _\$20	6.645	20	20	20	0	正常

12 全量样本特征提取结果续表

续表沿用相同字段与定义。全部记录的文本/语音/视觉维度均为 768/50/110，对齐粒度均为词级；磁盘保存完整变长序列，无补齐和 50 词截断。

表 9 全部样本的逐条结果 第 35 至 67 条

序号	样本编号	时长/s	词数	A	V	低分	状态
35	-iRBcNs9oI8\$_\$3	5.621	8	8	0	7	复核
36	-iRBcNs9oI8\$_\$7	4.104	9	9	0	9	复核
37	-iRBcNs9oI8\$_\$6	2.903	5	5	0	4	复核
38	-iRBcNs9oI8\$_\$9	3.416	5	5	0	5	复核
39	-iRBcNs9oI8\$_\$8	8.093	21	21	0	19	复核
40	-lZEya4AM_4\$_\$5	7.675	19	19	19	1	复核
41	-lZEya4AM_4\$_\$6	14.792	43	43	43	1	复核
42	-mJ2ud6oKI8\$_\$1	6.103	13	13	0	13	复核
43	-mJ2ud6oKI8\$_\$2	5.731	11	11	0	11	复核
44	-mJ2ud6oKI8\$_\$6	2.257	5	5	5	5	复核
45	-mJ2ud6oKI8\$_\$9	7.033	22	22	22	21	复核
46	-mJ2ud6oKI8\$_\$8	4.192	11	11	11	11	复核
47	-mqbVkbCndg\$_\$0	6.467	14	14	14	0	正常
48	-t217m2on-s\$_\$2	5.686	12	12	12	1	复核
49	-t217m2on-s\$_\$7	17.183	45	45	45	0	正常
50	-tANM6ETl_M\$_\$3	6.758	22	22	22	1	复核
51	-tPCytz4rww\$_\$11	5.467	17	17	17	2	复核
52	-tPCytz4rww\$_\$10	4.789	12	12	12	0	正常
53	-tPCytz4rww\$_\$12	11.864	26	26	26	2	复核
54	-tPCytz4rww\$_\$16	7.206	16	16	16	1	复核
55	-tPCytz4rww\$_\$18	6.645	16	16	16	0	正常
56	-vxjVxOeScU\$_\$4	9.127	21	21	21	3	复核
57	-wMB_hJL-3o\$_\$7	6.044	22	22	22	0	正常
58	-wny0OA3g8\$_\$1	6.844	22	22	1	0	复核
59	-wny0OA3g8\$_\$0	3.333	9	9	9	0	正常
60	-wny0OA3g8\$_\$3	6.146	20	20	0	0	复核
61	-wny0OA3g8\$_\$2	6.687	23	23	23	0	正常
62	-wny0OA3g8\$_\$5	6.912	20	20	1	0	复核
63	-wny0OA3g8\$_\$7	8.068	29	29	10	0	复核
64	-wny0OA3g8\$_\$9	6.213	20	20	20	0	正常
65	-571d8cVauQ\$_\$0	5.067	12	12	12	2	复核
66	-571d8cVauQ\$_\$5	15.273	43	43	43	1	复核
67	-I_e4mIh0yE\$_\$1	7.622	18	18	18	0	正常

注：复核状态还可能由数字读法、无人脸或多人脸提示触发，因此低分词数为 0 的样本仍可能需要复核。A/V 掩码表示存在有效源帧贡献，不能据此认定词区间已被完整覆盖。

12 全量样本特征提取结果续表

续表沿用相同字段与定义。全部记录的文本/语音/视觉维度均为 768/50/110，对齐粒度均为词级；磁盘保存完整变长序列，无补齐和 50 词截断。

表 9 全部样本的逐条结果 第 68 至 100 条

序号	样本编号	时长/s	词数	A	V	低分	状态
68	-I_c4mIh0yE\$_\$3	9.163	22	22	22	1	复核
69	-UacrmKiTn4\$_\$10	7.362	18	18	18	0	正常
70	-UacrmKiTn4\$_\$4	4.741	14	14	14	0	正常
71	-hnBHBN8p5A\$_\$7	7.372	13	13	0	13	复核
72	-hnBHBN8p5A\$_\$6	6.401	13	13	0	12	复核
73	-qDkUB0GgYY\$_\$6	4.678	16	16	16	3	复核
74	-uywlfYOS8\$_\$4	6.045	18	18	18	0	正常
75	-6rXp3zJ3kc\$_\$8	12.805	34	34	34	0	正常
76	-9y-fZ3swSY\$_\$0	6.833	22	22	22	4	复核
77	-9y-fZ3swSY\$_\$4	2.821	9	9	9	2	复核
78	-9y-fZ3swSY\$_\$8	4.989	12	12	5	0	复核
79	-AUZQgSxyPQ\$_\$2	22.511	41	41	41	3	复核
80	-HeZS2-Prhc\$_\$2	8.262	16	16	16	1	复核
81	-MeTTeMJBNC\$_\$0	9.300	21	21	21	0	正常
82	-MeTTeMJBNC\$_\$13	5.430	14	14	14	0	正常
83	-MeTTeMJBNC\$_\$7	10.517	31	31	31	1	复核
84	-RfYyzHpjk4\$_\$11	5.239	17	17	17	0	正常
85	-RfYyzHpjk4\$_\$8	4.589	17	17	17	0	正常
86	-RfYyzHpjk4\$_\$2	5.516	25	25	24	4	复核
87	-UUCSKoHeMA\$_\$0	7.800	18	18	18	0	正常
88	-ri04Z7vwnc\$_\$0	2.807	8	8	0	7	复核
89	-ri04Z7vwnc\$_\$2	6.027	16	16	8	16	复核
90	-ri04Z7vwnc\$_\$5	3.545	8	8	8	8	复核
91	-s9qJ7ATP7w\$_\$1	4.792	11	11	11	1	复核
92	-s9qJ7ATP7w\$_\$0	6.800	24	24	24	1	复核
93	-s9qJ7ATP7w\$_\$5	8.561	19	19	19	1	复核
94	-s9qJ7ATP7w\$_\$4	4.427	9	9	6	1	复核
95	-s9qJ7ATP7w\$_\$7	6.966	28	28	14	4	复核
96	-s9qJ7ATP7w\$_\$6	2.475	5	5	5	0	正常
97	-s9qJ7ATP7w\$_\$8	3.295	12	12	12	0	正常
98	-yRb-Jum7EQ\$_\$1	29.288	49	49	49	42	复核
99	-yRb-Jum7EQ\$_\$5	13.169	25	25	25	23	复核
100	-yRb-Jum7EQ\$_\$6	11.243	19	19	19	18	复核

合计：100 条样本，787.5022 秒，1931 词，A = 1931，V = 1601，低分词 342 个，含复核提示样本 69 条。状态“正常”仅表示未触发当前配置的提示规则，不代表人工确认无误。全部词级时间区间、帧级数值及源索引保存于配套特征和元数据中。